


Отчет по задержкам в аэропортах и их причинам в разрезе времени и атрибутов аэропорта

Задача по исследованию причин задержек и отмен включает в себя анализ количества и суммарного времени задержек рейсов в разрезе основных атрибутов, таких как:

- Дата рейса;
- Регион аэропорта;
- Тип аэропорта;
- Название аэропорта;
- Наличие информационного табло;
- Код перевозчика;
- Бортовой номер самолета;
- Причина задержки/отмены


В процессе выполнения данной задачи, была реализована **следующая схема ETL-процессов:**



Этап 1.

Логика загрузки файлов за выбранный период из S3 была реализована в DAG:

`rauzhakova_avia_s3_daily_check_and_copy`



Основные этапы:


- `check_yesterday_s3_folder`: проверка наличия файлов в S3 за предыдущий день. Если данные не найдены, то DAG падает с ошибкой, уведомляя об отсутствии данных за этот промежуток времени;
- `dbt_create_tables`: создание таблиц слоев ods, stg, dds;
- `truncate_postgres_tables`: очистка таблиц ods-слоя за предыдущий цикл для записи новых данных;
- `list_interval_files`: получение наименований файлов в S3 за предыдущий день;
- `copy_to_postgres`: копирование данных в таблицы ods-слоя;
- `copy_airports_to_postgres`: скачивание и копирование справочника аэропортов в таблицу ods-слоя (осуществляется один раз в момент создания таблицы);

- `copy_regions_to_postgres`: скачивание и копирование справочника регионов в таблицу ods-слоя (осуществляется один раз в момент создания таблицы);
- `trigger_avia_copy_to_stg`: задача триггер, при успешном выполнении всех задач DAG, автоматически запускает следующий DAG.

Этап 2.

Логика загрузки данных (успешные / отмененные рейсы) из ODS в STG в DAG:

`rauzhakova_avia_copy_to_stg`



Основные этапы:

- `install_dependencies`: установка (при необходимости) библиотеки для определения часового пояса по координатам долготы и широты аэропорта;
- `copy_cancelled_flights_to_stg`: копирование данных по отмененным рейсам из слоя ods, подготовка и преобразование данных, перевод локального времени в формат UTC, загрузка данных в stg;
- `copy_success_flights_to_stg`: копирование данных по успешным рейсам из слоя ods, подготовка и преобразование данных, перевод локального времени в формат UTC, загрузка данных в stg;

- [trigger_avia_copy_to_dds](#): задача триггер, при успешном выполнении всех задач DAG, автоматически запускает следующий DAG.

Итоговые таблицы успешных и отмененных рейсов с атрибутами


success_flights	
carrier_flight_num BIGINT	Номер рейса перевозчика
sched_dttm_local TIMESTAMPTZ	Локальное время и дата вылета
flight_dttm_local TIMESTAMPTZ	Локальное фактическое время и дата вылета
sched_arr_dttm_local TIMESTAMPTZ	Локальное время и дата прилета
flight_arr_dttm_local TIMESTAMPTZ	Локальное фактическое время и дата прилета
origin_airport_dk VARCHAR(5)	Код аэропорта отправления
dest_airport_dk VARCHAR(5)	Код аэропорта назначения
carrier_code VARCHAR(5)	Код перевозчика
tail_num VARCHAR(20)	Бортовой номер самолета
distance_m NUMERIC(10)	Дальность полета (мили)
dep_delay_min NUMERIC(10)	Задержка вылета (минуты)
arr_delay_min NUMERIC(10)	Задержка прилета (минуты)
delay_reasons_code VARCHAR(2)	Код причины задержки

cancelled_flights	
carrier_flight_num BIGINT	Номер рейса перевозчика
sched_dttm_local TIMESTAMPTZ	Локальное время и дата вылета
origin_airport_dk VARCHAR(5)	Код аэропорта отправления
dest_airport_dk VARCHAR(5)	Код аэропорта назначения
carrier_code VARCHAR(5)	Код перевозчика
tail_num VARCHAR(20)	Бортовой номер самолета
cancellation_code VARCHAR(2)	Код причины отмены

Этап 3.

Логика загрузки в DDS и организация хранения исторических данных в DAG:

[rauzhakova_avia_copy_to_dds](#)




Основные этапы:

- [copy_cancelled_flights_to_dds](#): копирование данных по отмененным рейсам из слоя STG в DDS, дедупликация данных за счет определения составного первичного ключа и внедрения конструкции on conflict, которая защищает витрину от заливки уже имеющихся данных. Отбор необходимых для дальнейшей аналитики полей;
- [copy_success_flights_to_dds](#): копирование данных по успешным рейсам из слоя STG в DDS, дедупликация данных за счет определения составного первичного ключа и внедрения конструкции on conflict, которая защищает витрину от заливки уже имеющихся данных. Отбор необходимых для дальнейшей аналитики полей;
- [copy_airports_dict_to_dds](#): копирование данных справочника аэропортов из слоя STG, предобработка данных, отбор необходимых для дальнейшей аналитики полей;

- **copy_regions_dict_to_dds:** копирование данных справочника регионов из слоя STG, предобработка данных, отбор необходимых для дальнейшей аналитики полей;
- **insert_cancellation_reasons_dict_to_dds:** создание справочника по причинам отмены рейсов;
- **insert_delay_reasons_dict_to_dds:** создание справочника по причинам задержки рейсов;
- **trigger_avia_copy_to_dm:** задача триггер, при успешном выполнении всех задач DAG, автоматически запускает следующий DAG.


Логическая модель для слоя DDS



Этап 4.

Логика агрегации данных из слоя DDS в DM в DAG:

`rauzhakova_avia_copy_to_dm`



Основные этапы:

- `create_and_truncate_views`: создание представлений слоя DM, очистка имеющихся данных перед новой заливкой;
- `update_cancelled_flights_view`: обновление и агрегация данных в представлении по отмененным рейсам;
- `update_delayed_flights_view`: обновление и агрегация данных в представлении по задержанным рейсам;
- `update_success_flights_view`: обновление и агрегация данных в представлении по успешным рейсам;

Витрины слоя DM

cancelled_flights		delayed_flights		success_flights	
flight_date DATE	Дата рейса	flight_date DATE	Дата вылета	flight_date DATE	Дата вылета
region_name TEXT	Регион аэропорта	region_name TEXT	Регион аэропорта	region_name TEXT	Регион аэропорта
municipality VARCHAR(100)	Муниципалитет аэропорта	municipality VARCHAR(100)	Муниципалитет аэропорта	municipality VARCHAR(100)	Муниципалитет аэропорта
airport_type VARCHAR(20)	Тип аэропорта	airport_type VARCHAR(20)	Тип аэропорта	airport_type VARCHAR(20)	Тип аэропорта
airport_name TEXT	Наименование аэропорта	airport_name TEXT	Наименование аэропорта	airport_name TEXT	Наименование аэропорта
is_sched_service INTEGER	Наличие информационного табло	is_sched_service INTEGER	Наличие информационного табло	is_sched_service INTEGER	Наличие информационного табло
carrier_code VARCHAR(5)	Код перевозчика	carrier_code VARCHAR(5)	Код перевозчика	carrier_code VARCHAR(5)	Код перевозчика
tail_num VARCHAR(20)	Бортовой номер самолета	tail_num VARCHAR(20)	Бортовой номер самолета	tail_num VARCHAR(20)	Бортовой номер самолета
cancel_reason VARCHAR(20)	Причина отмены	delay_reason VARCHAR(20)	Причина задержки	success_dep_flights_qty INTEGER	Кол-во отправленных успешных рейсов
canceled_flights_qty INTEGER	Кол-во отмененных рейсов	arr_delayed_flights_qty INTEGER	Кол-во прибывших задержанных рейсов	dep_flights_qty INTEGER	Кол-во отправленных рейсов
flights_qty INTEGER	Общее кол-во рейсов	any_arr_delayed_flights_qty INTEGER	Кол-во прибывших задержанных рейсов из-за задержки отправления/прибытия	success_arr_flights_qty INTEGER	Кол-во прибывших успешных рейсов
		arr_flights_qty INTEGER	Кол-во прибывших рейсов	arr_flights_qty INTEGER	Кол-во прибывших рейсов
		sum_arr_delay_min INTEGER	Суммарное время задержек по прибытию		
		dep_delayed_flights_qty INTEGER	Кол-во задержанных рейсов при отправлении		
		any_dep_delayed_flights_qty INTEGER	Кол-во отправленных задержанных рейсов из-за задержки отправления/прибытия		
		dep_flights_qty INTEGER	Кол-во отправленных рейсов		
		sum_dep_delay_min INTEGER	Суммарное время задержек по отправлению		

Слой DM включает в себя 3 витрины:

- **cancelled_flights**: универсальная витрина агрегатов кол-ва рейсов и суммарного времени задержки в разрезе основных атрибутов, рассчитанных для отмененных рейсов;
- **delayed_flights**: универсальная витрина агрегатов кол-ва рейсов и суммарного времени задержки в разрезе основных атрибутов, рассчитанных для задержанных рейсов;
- **success_flights**: универсальная витрина агрегатов кол-ва рейсов и суммарного времени задержки в разрезе основных атрибутов, рассчитанных для успешных рейсов.

Используемый подход для формирования витрины позволяет получить аналитику в любом нужно разрезе. Именно поэтому было рассчитано суммарное время задержки.

Этап 5.

Интеграция слоя DM с ClickHouse (создание таблиц-прокси для дашборда в DataLens)

Для обеспечения возможности построения дашборда в **Yandex DataLens** на основе финальных витрин DM-слоя была выполнена интеграция PostgreSQL с ClickHouse.

В соответствии с лекцией по интеграции систем был выбран подход с использованием табличного движка ENGINE = PostgreSQL. Данный движок позволяет создавать в ClickHouse **таблицы-прокси** (foreign tables), которые

не хранят данные локально, а выполняют запросы напрямую к соответствующим таблицам DM-слоя в PostgreSQL в реальном времени.

Преимущества выбранного подхода:

Отсутствие дублирования данных между PostgreSQL и ClickHouse;

- Данные всегда актуальны (live connection);
- Нет необходимости в дополнительных ETL-процессах или DAG для синхронизации;
- Возможность использовать мощные аналитические возможности ClickHouse поверх уже подготовленных витрин DM;
- Простота настройки и дальнейшей поддержки.

Реализованные таблицы в ClickHouse

В базе данных `rauzhakova_dm` ClickHouse были созданы три таблицы-прокси, полностью соответствующие витринам DM-слоя в PostgreSQL (схема `rauzhakova_dm`):

- `delayed_flights` — данные по задержанным рейсам (причины задержек + метрики суммарного времени опозданий);
- `cancelled_flights` — данные по отменённым рейсам (причины отмен);
- `success_flights` — данные по успешно выполненным рейсам.

Структура таблиц в ClickHouse

Типы данных адаптированы под аналитическую СУБД ClickHouse:

- `date` → `Date`
- текстовые поля (регион, муниципалитет, название аэропорта, код перевозчика, бортовой номер, причины) → `String`
- количественные показатели и суммы минут задержки → `UInt64`
- флаги → `UInt8`

Проверка работоспособности интеграции

После создания таблиц-прокси были выполнены контрольные запросы:

- Таблица `delayed_flights`: 555 561 запись, период с 02.03.2024 по 12.06.2024

- Таблица `cancelled_flights`: 11 809 записей, период с 02.03.2024 по 12.06.2024

- Таблица `success_flights`: 617 133 записи, период с 02.03.2024 по 12.06.2024

Все запросы выполнены успешно, данные полностью доступны.

Связь с витринами DM-слоя

Созданные таблицы-прокси напрямую отражают три универсальные витрины, построенные на Этапе 4:

- `cancelled_flights` — агрегаты количества рейсов и причин отмен в разрезе даты, региона, типа и названия аэропорта, перевозчика и других атрибутов;

- `delayed_flights` — агрегаты количества задержанных рейсов, суммарного времени задержек (в минутах) и причин задержек в тех же разрезах;

- `success_flights` — агрегаты успешно выполненных рейсов.

Благодаря этому в DataLens можно будет строить любые срезы аналитики (по дате, региону, аэропорту, перевозчику, причине и т.д.) без дополнительной обработки данных.